

Trabajo de señales: acoplamiento cardiopulmonar derivado del ECG como criterio de detección de apnea del sueño

16.63 - Procesamiento de Señales e Imágenes Biomédicas 2026Q2

Grupo 8

Augusto Frate – 65013

Karolina Tenca – 62751

Leah Weizman – 69550

Profesores

Roberto Sebastian Tomas

Francisco Tassara

Lucila Capurro

Victoria Reppucci

10 de noviembre de 2026

1. Introducción

1.1. Marco teórico

La apnea del sueño se caracteriza por episodios repetidos de interrupción o reducción de la respiración durante el descanso. En la apnea obstructiva, estos episodios se producen por el cierre total o parcial de la vía aérea superior, aunque se mantiene el esfuerzo respiratorio. Para su diagnóstico se utiliza la polisomnografía, que registra distintas señales fisiológicas y permite identificar los eventos respiratorios y su relación con el sueño. A partir de este estudio se calcula el índice de apnea-hipopnea (AHI), que expresa la cantidad de apneas e hipopneas por hora de sueño (Kapur et al. 2017).

El interés por detectar apnea a partir del ECG surge porque los episodios respiratorios también pueden manifestarse en la actividad cardíaca. Durante la apnea pueden aparecer variaciones cíclicas de la frecuencia cardíaca, que se observan en los intervalos entre picos R consecutivos. Estos intervalos forman la serie RR y permiten estudiar la variabilidad de la frecuencia cardíaca (HRV), tanto en el tiempo como en la frecuencia (Task Force 1996; Penzel et al. 2002). A su vez, la respiración modifica la posición del corazón respecto de los electrodos y la impedancia del tórax, lo que genera cambios en la amplitud y el área del complejo QRS. A partir de estas variaciones puede obtenerse una señal de respiración derivada del ECG, denominada EDR (Moody et al. 1985). De esta manera, un mismo registro permite obtener información sobre las variaciones cardíacas y respiratorias.

La relación entre ambas señales puede estudiarse mediante el análisis del acoplamiento cardiopulmonar. Para ello se utilizan medidas como la potencia cruzada, que permite identificar componentes compartidas en distintas frecuencias, y la coherencia, que cuantifica su asociación lineal normalizada. Thomas et al. (2005) utilizaron este enfoque para caracterizar distintos regímenes de acoplamiento durante el sueño. Este antecedente permite plantear que las oscilaciones lentas compartidas entre RR y EDR podrían aportar información para detectar apnea, además de la que ofrece el análisis de la variabilidad cardíaca por separado.

1.2. Estado del arte

La detección de apnea a partir del ECG fue el objetivo del PhysioNet/Computers in Cardiology Challenge 2000, para el cual se desarrolló la base Apnea-ECG utilizada en este trabajo. En una comparación de trece algoritmos participantes, Penzel et al. (2002) encontraron que los mejores resultados se obtenían al analizar características espectrales de los intervalos cardíacos y de las variaciones del ECG asociadas con la respiración. Dos de los métodos superaron el 90 % de exactitud en la clasificación por minuto, lo que mostró el potencial de estas señales para identificar episodios de apnea.

En esta misma línea, Chazal et al. (2003) combinaron características de los intervalos entre latidos y del EDR mediante clasificadores discriminantes lineales y cuadráticos, y alcanzaron una exactitud por minuto superior al 90 % en un conjunto independiente. Por su parte, el trabajo de Thomas et al. (2005) permitió estudiar la relación entre ambas señales desde el acoplamiento cardiopulmonar y vincularla con la estabilidad del sueño. Estos antecedentes motivan el uso conjunto de RR y EDR, aunque sus resultados corresponden a métodos y condiciones de evaluación que deben considerarse al compararlos con otras propuestas.

A partir de estos antecedentes, en este trabajo se estudia una feature conjunta RR–EDR basada en la potencia cruzada en la banda lenta asociada al ciclo de apnea. Se busca determinar si esta información permite mejorar la detección por minuto respecto de una feature basada únicamente en la variabilidad cardíaca, utilizando un punto de corte estadístico y sin aprendizaje automático. Las características y el umbral se eligen con los registros de desarrollo, mientras que la evaluación final se realiza sobre sujetos reservados para test. La propuesta se plantea como un análisis de la información contenida en el ECG y no como un reemplazo de la polisomnografía.

1.3. Objetivos e hipótesis

El objetivo es detectar la apnea del sueño minuto a minuto a partir del ECG, con un punto de corte estadístico y sin aprendizaje automático. Se plantean dos hipótesis:

H1. Durante la apnea aparece un acoplamiento lento entre la serie RR y el EDR, en la banda del ciclo de apnea (0,01 a 0,1 Hz), dentro de cada sujeto. El acoplamiento respiratorio (0,15 a 0,4 Hz) no desaparece.

H2. La feature conjunta RR–EDR (F) detecta la apnea mejor que la mejor feature de variabilidad cardíaca, que usa solo el RR.

2. Materiales y métodos

2.1. Base de datos y adquisición

Se usó la Apnea-ECG Database de PhysioNet (Penzel et al. 2000; Goldberger et al. 2000): 70 registros nocturnos de ECG de una derivación, muestreados a 100 Hz con 12 bits, con una etiqueta de apnea o normal por minuto asignada por un experto a partir de la polisomnografía. Ocho registros incluyen la respiración, que se usó solo para validar. Como a 100 Hz el pico R queda cuantizado a 10 ms, se lo ubica a ±30 ms de cada marca de QRS de la base, según la polaridad del registro, y se refina con una parábola de 3 puntos; el refinamiento se verificó con una prueba de dos fases a 50 Hz.

Tres pares de registros resultaron ser la misma grabación (c05/c06, x22/x35 y x33/x34); se excluyó uno de cada par y quedaron 67. Como la base no identifica a las personas, se agruparon los registros con igual perfil (edad, sexo, altura y peso), lo que dio 29 sujetos. La partición 70/30 se sorteó por sujeto con semilla 2026 (tabla 1), con cuotas exactas por categoría, una diferencia de 2 puntos o menos en la fracción de minutos con apnea y los registros con respiración en desarrollo.

Tabla 1: Partición por sujeto. Categoría A: 100 minutos de apnea o más; B: de 5 a 99; C: menos de 5.

Conjunto	A	B	C	Registros	Sujetos
Desarrollo	28	7	12	47	19
Test	12	3	5	20	10

2.2. Diseño de la evaluación

Todas las decisiones se tomaron con los registros de desarrollo, y test se evaluó una sola vez, al final. Como los minutos de una persona no son independientes, la unidad estadística es el sujeto: los intervalos de confianza al 95 % se obtienen por bootstrap de sujetos (Efron y Tibshirani 1993), con 2000 remuestreos en desarrollo y 10 000 en test. Se usan dos medidas: el área bajo la curva ROC por minuto, con todos los minutos juntos porque el detector aplica un único umbral, y el acierto por registro, definido como la correlación de Spearman entre la fracción de minutos con apnea estimada y la anotada.

Entre candidatas se retienen las no inferiores a la mejor en área bajo la curva (límite inferior del intervalo de la diferencia $\geq -0{,}02$) que además empatan en acierto por registro, y de ellas se elige la más simple. Esta regla reemplazó, después de una primera corrida, a la de declarar empate cuando el intervalo incluía el cero, que dejaba pasar candidatas ruidosas. Cada elección se controla con validación cruzada en 5 grupos de sujetos. Las etapas obligatorias se adoptan solo si F resulta no inferior en ambas medidas.

2.3. Preprocesamiento y detección de latidos

El ECG se filtra con un Butterworth pasabanda de 0,5 a 45 Hz y orden 3, aplicado ida y vuelta para no introducir desfase. La especificación se obtuvo de desarrollo sin usar etiquetas: atenuación de 1 dB o menos entre el ritmo cardíaco más bajo (0,77 Hz) y la frecuencia por debajo de la cual está el 99 % de la energía del latido (41,8 Hz), y de 20 dB o más a 0,1 Hz. Se eligió el menor orden que la cumple.

Como detector propio se implementó el algoritmo de Pan y Tompkins (1985) adaptado a 100 Hz: pasabanda de 5 a 15 Hz, derivada, cuadrado, integración en 150 ms y umbrales adaptativos con período refractario, discriminación de ondas T y búsqueda hacia atrás. Las etapas lineales están centradas, por lo que no introducen retardo, y el cuadrado hace al detector independiente de la polaridad del R. Se validó contra las marcas de la base con una tolerancia de 100 ms. Los intervalos RR fuera de 0,3 a 2 s o que se apartan más de 20 % de la mediana de sus 11 vecinos se reemplazan por interpolación. Se evalúan los minutos con etiqueta, con 20 % o menos de intervalos corregidos y con feature calculable (22 275 en desarrollo).

2.4. Recorte en realizaciones y filtro de Wiener

El ECG de cada registro se segmentó en realizaciones de −250 a +400 ms alineadas en el pico R. El promedio de las realizaciones estima la señal y el residuo, el ruido; con sus densidades espectrales se construye por registro $H(f) = S_s(f)/(S_s(f) + S_n(f))$, que se aplica al ECG continuo como un FIR simétrico de 129 coeficientes. Al ser lineal e invariante, el filtro aplica la misma ganancia a todos los latidos y preserva las variaciones de amplitud de las que se obtiene el EDR.

2.5. Segmentación y features

La unidad de decisión es el minuto. Las features espectrales se calculan en una ventana de 240 s centrada en cada minuto, elegida entre 3 y 8,5 min; resolver 0,01 Hz requiere segmentos de más de 100 s.

El EDR es el área con signo del QRS en ±60 ms alrededor de cada latido, sobre el ECG filtrado. Se eligió entre cinco métodos (Moody et al. 1985) por su coherencia con la respiración real y, al empatar con la deriva de línea de base, por su desempeño en la detección. RR y EDR se remuestrean a 2 Hz por interpolación cúbica. F es el logaritmo de la potencia cruzada RR–EDR promediada entre 0,01 y 0,05 Hz, estimada por el método de Welch (1967) con 3 segmentos de 120 s (ventana de Hann y 50 % de solapamiento), sin normalización por noche ni suavizado. La referencia de H2 es la mejor feature de variabilidad cardíaca (Task Force 1996) elegida con la misma regla: la potencia del RR entre 0,01 y 0,04 Hz en 180 s, estimada con el periodograma de Lomb (1976), que no requiere interpolar el RR. En ambos casos, un minuto se clasifica como apnea si la feature supera el umbral que maximiza el índice de Youden (1950) en desarrollo (figura 1).

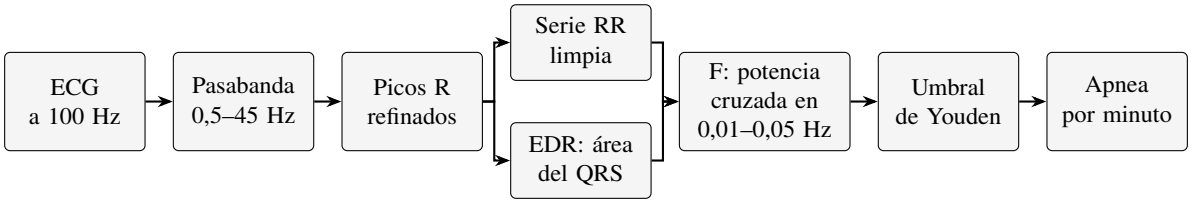


Figura 1: Detector propuesto. La referencia de H2 usa solo la serie RR.

2.6. Análisis estadístico y evaluación en test

H1 se evaluó en los registros A y B de desarrollo (35 registros, 14 sujetos) con el cociente entre la coherencia RR–EDR lenta y la respiratoria, en ventanas de 512 s y con dos pares de bandas fijados de antemano: los del acoplamiento cardiopulmonar de Thomas et al. (2005) (0,01–0,1 y 0,1–0,4 Hz) y los de la versión anterior del trabajo (0,01–0,15 y 0,15–0,4 Hz). Para cada sujeto se calculó la diferencia de medianas entre minutos con y sin apnea, promediada entre sus registros, y se aplicó la prueba de Wilcoxon de rangos con signo con corrección de Holm (1979); el tamaño del efecto es el rango-biserial.

La estimación honesta de desarrollo se obtuvo con validación cruzada anidada por sujetos, que repite toda la elección (feature, posprocesamiento y umbral) sin los sujetos de evaluación. En test, H2 se evalúa con dos medidas principales: M1, el área bajo la curva por minuto, y M2, el acierto por registro. Para cada una se calcula la diferencia entre F y la referencia, con su intervalo al 95 % y un valor p bilateral por bootstrap corregido por Holm; H2 se confirma en una medida si $p < 0{,}05$ a favor de F. Como resultados secundarios se reportan la sensibilidad, la especificidad y la exactitud por minuto, la categoría de cada noche (A, B, C y A contra el resto), los minutos de apnea por hora con Bland–Altman (Bland y Altman 1986), la correlación con el índice de apnea-hipopnea y la réplica de H1. La clasificación A contra el resto se agregó tras observar en desarrollo que el detector, al sobreestimar la apnea, deja las noches de control como B.

2.7. Implementación

Se implementó en Python (NumPy, SciPy, pandas, Matplotlib y wfdb), con pruebas automáticas y un notebook por etapa. El código y las instrucciones para reproducir los resultados están en `https://github.com/afrateitba/TP-PSB-G8`.

3. Resultados

3.1. Decisiones en desarrollo

Tabla 2: Resultados que sostienen cada decisión, en los 47 registros de desarrollo. Área: área bajo la curva por minuto; acierto: acierto por registro; límite: límite inferior del intervalo de la diferencia.

Etapa	Resultado
Sujetos	Correlación mediana entre latidos promedio: 0,94 dentro del sujeto y 0,74 entre sujetos.
Refinamiento del R	Desacuerdo entre fases de 10,0 a 2,5 ms; se mantiene.
Filtro	F no inferior al filtro anterior (área 0,876 $\rightarrow$ 0,875); se adopta.
Detector propio	Sensibilidad 0,996 y valor predictivo positivo 0,972, pero F no es no inferior en acierto (límite $-0{,}097$); no se adopta.
Filtro de Wiener	F no es no inferior en acierto (límite $-0{,}165$); no se adopta.
Señal perdida	Excluir esos minutos no es no inferior (límite $-0{,}0209$); no se excluyen.
EDR	Coherencia del área del QRS con la respiración real: 0,53 (azar 0,16).
Feature	F: área 0,871; mejor variabilidad cardíaca (muy baja frecuencia): 0,810.
Coherencia	No aporta: F sin ella da 0,874; la coherencia sola, 0,63.
Posprocesamiento	Normalizar o suavizar no mejora; con ventana de 4 min, área 0,876.
Umbral	F $\geq -6{,}9486$: sensibilidad 0,84 y especificidad 0,75.

La tabla 2 resume las decisiones tomadas en desarrollo. El filtro pasabanda de 0,5 a 45 Hz se incorporó porque cumplió las especificaciones y mantuvo el desempeño de F según el criterio de no inferioridad. En cambio, el detector QRS propio y el filtro de Wiener no se incorporaron al detector final: aunque cumplieron el criterio en el área bajo la curva por minuto, no lo hicieron en el acierto por registro. Por lo tanto, se conservaron las marcas de QRS de la base, con el refinamiento del pico R, y el ECG filtrado sin Wiener.

Para construir el EDR se eligió el área del QRS, que presentó una coherencia con la respiración real superior a la obtenida por azar. En la comparación de features, la potencia cruzada RR–EDR mostró un área bajo la curva de 0,871, frente a 0,810 de la mejor feature basada solo en RR. Agregar la coherencia no mejoró la detección, por lo que se conservó la potencia cruzada sin ese componente. Esto indica que, entre las alternativas evaluadas, resultó más útil la magnitud de las oscilaciones compartidas que su asociación lineal normalizada.

Finalmente, la normalización por noche y el suavizado tampoco mejoraron el desempeño. Se eligió una ventana de 240 s, sin estas operaciones, y un umbral de Youden de $-6{,}9486$, con el que se obtuvo una sensibilidad de 0,84 y una especificidad de 0,75 en desarrollo. Estos resultados se utilizaron para definir el detector; su desempeño en sujetos no utilizados en la selección se presenta en las evaluaciones siguientes.

3.2. Hipótesis 1

En los registros A y B de desarrollo, el cociente entre la coherencia lenta y la respiratoria aumentó durante la apnea en 11 de los 14 sujetos evaluados. Con las bandas del acoplamiento cardiopulmonar publicado, el tamaño del efecto rango-biserial fue de 0,81 y el valor p corregido por Holm fue de 0,011. Las 36 configuraciones evaluadas mostraron cambios en la dirección planteada por H1, aunque esto no implica que todas alcanzaran significancia estadística.

Al analizar la coherencia respiratoria por separado, no se detectó una disminución durante la apnea (p de Holm = 1). En conjunto, estos resultados son compatibles con la aparición de un acoplamiento lento adicional, más que con un desplazamiento del acoplamiento respiratorio hacia frecuencias menores. Sin embargo, la ausencia de una diferencia significativa no permite afirmar que la coherencia respiratoria se mantenga sin cambios.

Como control, se repitió el análisis reemplazando el EDR por la respiración registrada. El efecto apareció en los cinco registros con apnea que contaban con esta señal, lo que respalda que el comportamiento observado no depende únicamente de la construcción del EDR. Estos resultados corresponden a desarrollo; su réplica en sujetos reservados se presenta en la evaluación en test.

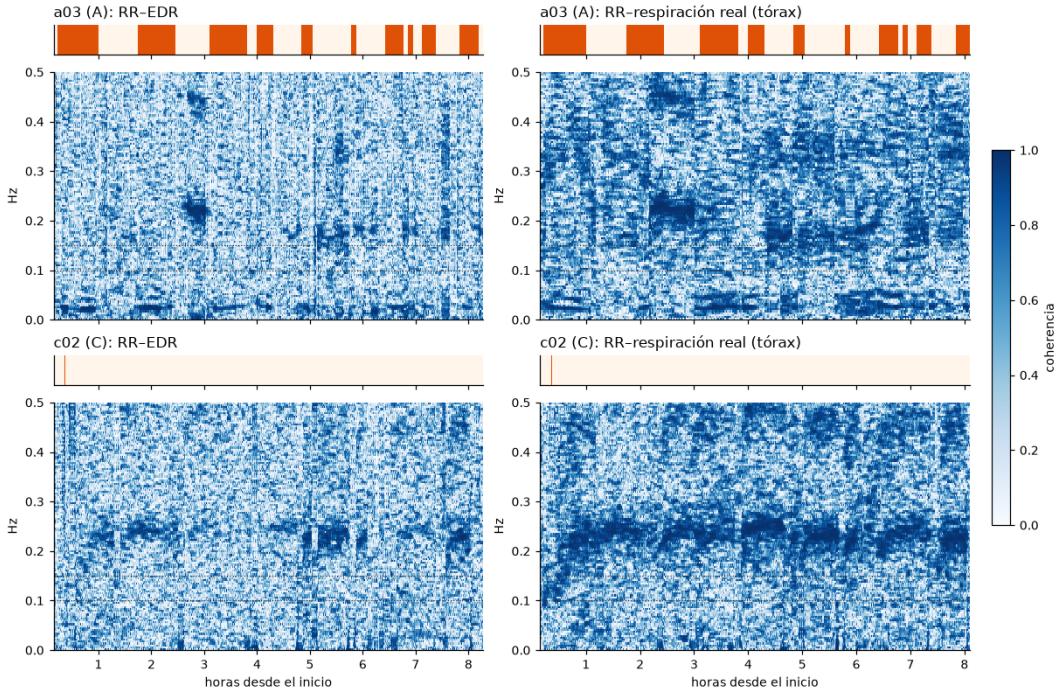


Figura 2: Mapas nocturnos de coherencia del registro a03 (categoría A) y c02 (control). Se compara la serie RR con el EDR (izquierda) y con la respiración torácica registrada (derecha), utilizando ventanas de 512 s. La intensidad del azul representa la coherencia y las franjas naranjas superiores indican los minutos anotados con apnea. Las líneas punteadas señalan 0,10 y 0,15 Hz, límites de las bandas evaluadas.

3.3. Estimación honesta en desarrollo

Al repetir la elección de la feature, el posprocesamiento y el umbral mediante validación cruzada anidada por sujetos, F obtuvo un área bajo la curva media entre grupos de 0,851, con un intervalo de confianza del 95 % de 0,760 a 0,916. La sensibilidad fue de 0,839, la especificidad de 0,748 y el acierto por registro de 0,807. El área bajo la curva disminuyó 0,024 respecto de la obtenida al elegir y evaluar el detector con todos los sujetos de desarrollo.

Los cinco grupos eligieron la misma configuración de F: potencia cruzada RR–EDR con una ventana de 240 s, sin normalización ni suavizado. Los umbrales variaron entre −6,96 y −6,91. En cambio, la feature de referencia de HRV cambió entre grupos y obtuvo un área bajo la curva media de 0,729. La diferencia a favor de F fue de 0,122, con un intervalo de confianza del 95 % de 0,022 a 0,193. Esta comparación es descriptiva: la evaluación final de H2 se realiza en test con las configuraciones fijadas en desarrollo.

Aunque F permitió ordenar las noches según su fracción de apnea, presentó una sobreestimación de los minutos afectados. El sesgo fue de +5,0 minutos de apnea por hora, con límites de acuerdo de −21,1 a +31,0. La categoría A/B/C fue correcta en el 57 % de las noches y las doce noches de control se clasificaron como B. Al considerar únicamente la separación entre las noches A y el resto, el porcentaje de clasificación correcta fue del 83 %. Estos resultados muestran que la capacidad de ordenar los registros no asegura una estimación precisa de la cantidad de apnea ni de la categoría de cada noche.

3.4. Evaluación en test

Tabla 3: H2 en test (20 registros, 10 sujetos), corrido una sola vez sobre `congelado-test`. Intervalo al 95 % con 10 000 remuestreos de sujetos; p bilateral corregido por Holm.

Medida	F	Referencia (VLF)	Diferencia (IC 95 %)	p de Holm
M1: área bajo la curva por minuto	0,785	0,793	−0,007 (−0,162 a +0,112)	1,00
M2: acierto por registro	0,634	0,613	+0,021 (−0,543 a +0,514)	1,00

Ninguna de las dos medidas muestra diferencia (Tabla 3): H2 no se confirma ni se rechaza con estos datos. Con 10 sujetos los intervalos son muy anchos, así que el resultado tampoco indica que F y la referencia sean equivalentes. Se evaluaron 8.556 de los 9.754 minutos con etiqueta (el 12,3 % queda afuera, casi todo de c04 y x29, por la regla del 20 % de RR corregidos). Los resultados secundarios están en la Tabla 4.

Tabla 4: Resultados secundarios en test, con los umbrales de desarrollo.

	Medida	F	Referencia (VLF)
Por minuto	Sensibilidad	0,790	0,735
	Especificidad	0,642	0,686
	Exactitud	0,706	0,707
Por noche	Sesgo (min de apnea por hora)	+7,3	+5,1
	Límites de acuerdo	−27,9 a +42,5	−25,4 a +35,6
	Categoría A/B/C correcta	45 %	60 %
	A contra el resto correcta	70 %	70 %
	Spearman con el AHI (IC 95 %)	0,70 (0,15 a 0,91)	0,68 (−0,04 a 0,91)

F sobreestima la apnea, como en desarrollo: las 5 noches C quedan como B. **H1 no se replica**: en los 15 registros A/B de test (8 sujetos), el cociente de coherencias sube con la apnea en solo 4 de 8 sujetos (CPC publicado) y 3 de 8 (esquema v2), con p de Holm 1. Con todos los minutos con etiqueta, ninguna conclusión cambia.

4. Discusión

Los resultados de desarrollo indicaron que la información conjunta RR–EDR podía aportar a la detección de apnea, pero esa ventaja no se sostuvo en test. En la validación cruzada anidada, F obtuvo un área bajo la curva de 0,851 frente a 0,729 de la referencia, mientras que en test los valores fueron 0,785 y 0,793, respectivamente. Tampoco se observó una ventaja clara en el acierto por registro. Por lo tanto, los resultados finales no permiten afirmar que incorporar el EDR mejore la detección respecto del análisis del RR. Los intervalos amplios impiden concluir equivalencia, pero la falta de superioridad no puede atribuirse únicamente al tamaño de la muestra: las diferencias puntuales en test también fueron pequeñas.

Esta comparación de desarrollo, sin embargo, sobrestimaba la ventaja de F. En la validación anidada, la referencia se volvía a elegir dentro de cada grupo y su selección fue inestable: dos de los cinco grupos obtuvieron un área bajo la curva cercana a 0,53, uno de ellos tras elegir el cociente entre baja y alta frecuencia, lo que redujo el promedio a 0,729. La referencia congelada, elegida con todo desarrollo, alcanzó 0,810 en desarrollo y 0,793 en test, es decir, se mantuvo estable. Frente a esa referencia, la ventaja de F por minuto ya era incierta en desarrollo: 0,876 contra 0,810, con una diferencia de 0,066 cuyo intervalo de confianza del 95 % incluía el cero (−0,004 a +0,142). En consecuencia, el cambio entre desarrollo y test se explica principalmente por la caída de F, de 0,851 en la validación anidada a 0,785, y no por una mejora de la referencia. La ventaja más clara de desarrollo estaba en el acierto por registro (0,81 frente a 0,42), y es también la que menos se reprodujo (0,634 frente a 0,613), en una medida que, con 20 registros y cinco de ellos casi sin apnea, resulta especialmente variable.

La interpretación de H1 requiere la misma cautela. En desarrollo, el aumento del cociente de coherencias fue compatible con la aparición de un acoplamiento lento durante la apnea, sin una disminución estadísticamente detectable de la coherencia respiratoria. Sin embargo, esta última observación no demuestra que el acoplamiento respiratorio se conserve. Además, H1 no se replicó en test: el cambio tuvo la dirección esperada en solo cuatro de ocho sujetos con las bandas del CPC publicado. Esto limita la generalización del comportamiento observado en desarrollo. También debe reconocerse que la formulación de H1 se modificó después de analizar esos datos: se pasó de proponer un desplazamiento del acoplamiento hacia frecuencias menores a plantear la aparición de un componente lento adicional. La reformulación permite describir mejor lo observado, pero su respaldo en desarrollo tiene un componente exploratorio y necesita confirmación independiente.

Por otra parte, el resultado de H1 y la utilidad de F responden preguntas diferentes. H1 estudia un cociente de coherencias, mientras que el detector final utiliza potencia cruzada sin ponderarla por coherencia. Que esta

última no mejorara la clasificación indica que, entre las alternativas evaluadas, su incorporación no aportó desempeño adicional. No demuestra que la coherencia carezca de interés fisiológico ni que F mida por sí sola una relación causal entre respiración y ritmo cardíaco. Al conservar una medida de potencia sin normalización por noche, también se retienen diferencias de amplitud entre registros. Estas podrían influir en la aplicación de un umbral común, aunque este trabajo no permite separar su contribución de la asociada con la apnea.

La separación por sujetos, la exclusión de grabaciones duplicadas y el uso de test una sola vez redujeron el riesgo de evaluar el método sobre información utilizada para elegirlo. No obstante, la validación anidada tampoco elimina todo el optimismo del desarrollo. Dentro de cada grupo se repitió la selección de features, posprocesamiento y umbral, pero algunas decisiones previas, como la incorporación de la banda de apnea y la regla de selección, se habían definido observando el conjunto completo. Además, la regla de empate se reemplazó por una de no inferioridad después de una primera corrida. Estos cambios fueron documentados, pero su documentación no elimina la adaptación a los datos. La estabilidad de F en los cinco grupos muestra consistencia dentro de desarrollo, sin garantizar su generalización a otros sujetos. A esto se suma que la identidad de las personas se infirió a partir de sus perfiles y de la comparación de señales, en lugar de contar con identificadores confirmados.

Las etapas de preprocesamiento también deben interpretarse según el alcance de su evaluación. El filtro pasabanda se eligió a partir de una especificación obtenida sin etiquetas y mantuvo el desempeño del detector. En cambio, el detector QRS propio y Wiener no cumplieron el criterio de no inferioridad en el acierto por registro. Esto justifica no incorporarlos según la regla fijada, pero no demuestra que sean inferiores ni que carezcan de utilidad para otros objetivos. El margen de 0,02 fue una tolerancia metodológica, sin una justificación clínica específica, y su uso en medidas distintas no supone consecuencias equivalentes. La evaluación conjunta por minuto y por registro evitó adoptar etapas solo por una mejora local, aunque también hizo depender su aceptación de la precisión de ambas estimaciones.

En particular, el detector final conserva las marcas QRS de la base, por lo que su desempeño no representa todavía el de un sistema autónomo que recibe únicamente el ECG. La revisión manual de discrepancias mostró errores tanto del detector propio como de las marcas de referencia, además de casos dudosos. Por eso, las métricas de detección de latidos no deben interpretarse como si la referencia fuera perfecta. Del mismo modo, la mejora del refinamiento parabólico en la prueba de dos fases respalda una menor sensibilidad a la posición de muestreo, pero no establece el error absoluto del pico R frente a una referencia independiente de mayor frecuencia de muestreo.

La ventana de 240 s permitió estimar las componentes lentas de interés, a costa de una menor resolución temporal. Aunque se produce una decisión por minuto, cada valor de F incorpora información de minutos vecinos. En desarrollo, el 27 % de los falsos positivos se ubicó a uno o dos minutos de una apnea; al excluir los bordes de los episodios, la especificidad aumentó de 0,748 a 0,796. Esto es compatible con un efecto de mezcla temporal, pero no explica todos los errores. Los falsos negativos se concentraron principalmente en el interior de episodios largos y en pocos sujetos, lo que sugiere que el umbral común no representa de igual manera a todas las personas. Además, la ventana centrada y el filtrado ida y vuelta utilizan muestras futuras: la implementación evaluada corresponde a un análisis fuera de línea y requeriría modificaciones para funcionar en tiempo real.

El tratamiento de la calidad constituye otra limitación. Los límites de corrección del RR y la exclusión de minutos con más del 20 % de intervalos corregidos no se justificaron mediante una evaluación específica de esas tolerancias. En test quedó afuera el 12,3 % de los minutos con etiqueta, concentrado principalmente en dos registros. En consecuencia, el desempeño principal describe los minutos que cumplen las condiciones de evaluación y no toda la grabación. El análisis con todos los minutos no modificó las conclusiones, aunque completar decisiones inválidas con la del minuto válido más cercano no demuestra que el detector funcione correctamente en esos segmentos. En desarrollo también se observó una alta tasa de falsos positivos cuando la ventana contenía señal perdida. Aunque estos casos representaron una fracción pequeña del total, muestran que la interpolación puede introducir variaciones lentas que se confundan con la información buscada.

La elección del umbral de Youden favoreció un equilibrio entre sensibilidad y especificidad, pero no garantizó una estimación precisa de la cantidad de apnea por noche. En test, F alcanzó una sensibilidad de 0,790 y una especificidad de 0,642, con un sesgo de +7,3 minutos de apnea por hora y límites de acuerdo amplios. Las cinco noches de control se clasificaron como B. Esto muestra por qué una correlación positiva entre las fracciones estimadas y anotadas no equivale a concordancia: el detector puede ordenar razonablemente

los registros y sobreestimar sus valores. La clasificación A contra el resto simplificó el resultado, pero fue incorporada después de observar los problemas de la matriz A/B/C en desarrollo y debe mantenerse como análisis secundario. Tampoco la correlación con el AHI permite afirmar que se estime la gravedad clínica, ya que el detector cuenta minutos afectados, mientras que el AHI cuenta eventos por hora de sueño.

Los resultados publicados por Penzel et al. (2002) y Chazal et al. (2003), con exactitudes por minuto superiores al 90 %, muestran que existe información útil para detectar apnea en el ECG. Sin embargo, no constituyen una comparación directa con este trabajo, porque difieren los clasificadores, las particiones y las condiciones de evaluación. La propuesta basada en una feature y un umbral facilita describir la decisión, pero esa simplicidad no asegura una mejor generalización. En este caso, su aporte principal fue permitir analizar de manera explícita qué información se conserva y dónde falla el criterio. Una continuación debería abordar cada limitación con datos nuevos o una evaluación separada: evaluar F en una cohorte independiente con más sujetos, para tener potencia suficiente; estudiar la estabilidad del umbral entre personas y una calibración por noche que corrija la sobreestimación; justificar con datos las reglas de calidad del RR; corregir en el detector QRS propio la confusión con ondas T empinadas y su arranque sobre tramos con artefacto, para poder prescindir de las marcas de la base; y adaptar la ventana y el filtrado a un esquema causal si se busca un uso en tiempo real.

5. Conclusiones

H1 se sostuvo en desarrollo: durante la apnea aumentó la coherencia lenta entre RR y EDR en 11 de 14 sujetos, sin una disminución detectable de la respiratoria, pero no se replicó en test (4 de 8 sujetos). H2 no se confirmó: en test, F obtuvo un área bajo la curva de 0,785 frente a 0,793 de la referencia y un acierto por registro de 0,634 frente a 0,613, sin diferencias significativas. De los temas obligatorios, el detector final conserva el filtro pasabanda diseñado a partir de los datos, el refinamiento del pico R, la segmentación en ventanas de 240 s y la potencia espectral con Lomb como referencia; el detector QRS propio y el filtro de Wiener se evaluaron y no se incorporaron por no cumplir la no inferioridad en el acierto por registro. La principal limitación es el tamaño de test: con 10 sujetos los intervalos son demasiado amplios para afirmar superioridad o equivalencia. Para resolverlo, el paso siguiente es evaluar el criterio en una cohorte independiente y más grande, con un detector de latidos propio y reglas de calidad justificadas con datos.

Referencias

Bland, J. M. y D. G. Altman (1986). «Statistical Methods for Assessing Agreement Between Two Methods of Clinical Measurement». En: *The Lancet* 327.8476, págs. 307-310. DOI: 10.1016/S0140-6736(86)90837-8.

Chazal, P. de, C. Heneghan, E. Sheridan, R. Reilly, P. Nolan y M. O'Malley (2003). «Automated Processing of the Single-Lead Electrocardiogram for the Detection of Obstructive Sleep Apnoea». En: *IEEE Transactions on Biomedical Engineering* 50.6, págs. 686-696. DOI: 10.1109/TBME.2003.812203.

Efron, B. y R. J. Tibshirani (1993). *An Introduction to the Bootstrap*. New York: Chapman & Hall.

Goldberger, A. L., L. A. N. Amaral, L. Glass, J. M. Hausdorff, P. C. Ivanov, R. G. Mark, J. E. Mietus, G. B. Moody, C.-K. Peng y H. E. Stanley (2000). «PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals». En: *Circulation* 101.23, e215-e220. DOI: 10.1161/01.CIR.101.23.e215.

Holm, S. (1979). «A Simple Sequentially Rejective Multiple Test Procedure». En: *Scandinavian Journal of Statistics* 6.2, págs. 65-70.

Kapur, V. K., D. H. Auckley, S. Chowdhuri, D. C. Kuhlmann, R. Mehra, K. Ramar y C. G. Harrod (2017). «Clinical Practice Guideline for Diagnostic Testing for Adult Obstructive Sleep Apnea: An American Academy of Sleep Medicine Clinical Practice Guideline». En: *Journal of Clinical Sleep Medicine* 13.3, págs. 479-504. DOI: 10.5664/jcsm.6506.

Lomb, N. R. (1976). «Least-Squares Frequency Analysis of Unequally Spaced Data». En: *Astrophysics and Space Science* 39.2, págs. 447-462. DOI: 10.1007/BF00648343.

Moody, G. B., R. G. Mark, A. Zoccola y S. Mantero (1985). «Derivation of Respiratory Signals from Multi-Lead ECGs». En: *Computers in Cardiology 1985*. Vol. 12, págs. 113-116.

Pan, J. y W. J. Tompkins (1985). «A Real-Time QRS Detection Algorithm». En: *IEEE Transactions on Biomedical Engineering* BME-32.3, págs. 230-236. DOI: 10.1109/TBME.1985.325532.

Penzel, T., J. McNames, P. de Chazal, B. Raymond, A. Murray y G. Moody (2002). «Systematic Comparison of Different Algorithms for Apnoea Detection Based on Electrocardiogram Recordings». En: *Medical & Biological Engineering & Computing* 40.4, págs. 402-407. DOI: 10.1007/BF02345072.

Penzel, T., G. B. Moody, R. G. Mark, A. L. Goldberger y J. H. Peter (2000). «The Apnea-ECG Database». En: *Computers in Cardiology 2000*. Vol. 27, págs. 255-258. DOI: 10.1109/CIC.2000.898505.

Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology (1996). «Heart Rate Variability: Standards of Measurement, Physiological Interpretation and Clinical Use». En: *Circulation* 93.5, págs. 1043-1065. DOI: 10.1161/01.CIR.93.5.1043.

Thomas, R. J., J. E. Mietus, C.-K. Peng y A. L. Goldberger (2005). «An Electrocardiogram-Based Technique to Assess Cardiopulmonary Coupling during Sleep». En: *Sleep* 28.9, págs. 1151-1161. DOI: 10.1093/sleep/28.9.1151.

Welch, P. D. (1967). «The Use of Fast Fourier Transform for the Estimation of Power Spectra: A Method Based on Time Averaging over Short, Modified Periodograms». En: *IEEE Transactions on Audio and Electroacoustics* 15.2, págs. 70-73. DOI: 10.1109/TAU.1967.1161901.

Youden, W. J. (1950). «Index for Rating Diagnostic Tests». En: *Cancer* 3.1, págs. 32-35.

A. Detalles de métodos y resultados

Revisión manual de las discrepancias del detector propio

Se sortearon 50 discrepancias entre el detector propio y las marcas de la base (semilla 2026, antes de mirarlas) y se clasificaron viendo 10 s de ECG alrededor de cada una (`docs/revision_qrs_50.csv`). La muestra está dominada por x17 (14 de 50), porque se sorteó sobre todas las discrepancias.

Tabla 5: Clasificación de las 50 discrepancias revisadas.

Clase	Casos	Patrón principal
Error del detector	21	Detección adicional al final de una onda T empinada (x17, x12); oscilaciones rápidas al inicio del registro (c01, x04, c09).
Error de las marcas de la base	18	QRS claros sin marca, a menudo negativos o bifásicos.
Dudoso	11	Artefacto o ruido que impide decidir.

Sin los dudosos, el detector explica 21 de 39 discrepancias: una diferencia con las marcas de la base no es necesariamente un error del detector.